

# 第 4 组联调与集成报告

第 4 组（工具服务层）与 5 组系统集成、真实 LLM 联调、端到端演示

- 报告日期：2026-09-09（最终定稿）
- 对应检查点：检查点 3（联调测试报告 + 集成演示）、检查点 4（完整系统）

## 一、联调范围与方法

| 联调对象              | 联调内容                                                                   | 方式        |
|-------------------|------------------------------------------------------------------------|-----------|
| 与第 3 组（执行层）       | <code>call(name, params)</code> → <code>tool_result_json</code> 契约     | 接口探针 + 真机 |
| 与第 2 组（任务规划）      | 工具/技能清单对接                                                              | 静态 + 探针   |
| 与第 5 组（协调/安全/RAG） | 调用统计/审计时间戳/签名                                                          | 接口 + 探针   |
| 全体（跨组）            | <code>MockToolRegistry</code> （61 工具同构）                                | 全量测试      |
| 真实 LLM            | 阿里云百炼 <code>qwen3.5-plus</code> <code>function-calling</code> 驱动多步工具调用 | 真机联调（含证据） |

## 二、真机联调证据

### 2.1 真实 LLM 驱动文件系统工具（阿里云百炼）

- 环境：阿里云 DashScope `compatible-mode`，模型 `qwen3.5-plus`，`function-calling` 真实生效。
- 成果：真实 LLM 自主规划并连续调用 `list_directory` → `read_text_file` → `copy/move` → `run_command` 完成多步文件操作，全程零人工干预。
- 证据：`docs/evidence/agent_qwen_live.md`（含真实调用链）。

### 2.2 邮件技能联调（SMTP + IMAP 闭环）

- 成果：`send_email` 组合技能 SMTP 发送 + IMAP 回读到达收件箱核验闭环，验证了“外发副作用工具”在真机的可用性与可核验性。
- 证据：`docs/evidence/email_live_qq.md`。

### 2.3 QQ 通信技能联调（Windows 桌面）

- 成果：`read_qq_chat` / `app_send_message` 经屏幕 OCR 核对会话标题后读写聊天，组合技能“一步到位”而非零散点击。

- 证据： docs/evidence/qq\_group\_一中兄弟会\_\*.png + evidence/README.md 。

2.4 百炼服务端工具（联网搜索 / 代码解释器）

- 联网搜索： enable\_search 服务端搜索，云端返回带参考来源，实测模型可据此作答。
- 代码解释器：纯计算回合自动启用，实测 qwen3.7-flash / qwen3.5-plus 精确计算  $123^{2^1}$ ，模型不支持时自动探测停用。
- 证据： examples/probe\_bailian\_code\_interpreter.py + 配置注释。

三、端到端演示场景核对（设计书演示场景表）

| 演示场景              | 第 4 组支撑                                               | 状态    |
|-------------------|-------------------------------------------------------|-------|
| 场景 1 打开文件管理器      | app_open 工具                                           | ✓     |
| 场景 2 导航到目录        | 工具层确定性路径能力 + list_directory                           | ✓     |
| 场景 3 创建文件夹        | create_directory 工具                                   | ✓     |
| 场景 4 编辑文件         | edit_file / write_text_file / read_text_file          | ✓     |
| 场景 5 切换窗口         | activate_window / switch_app 工具                       | ✓     |
| 场景 6 整理下载目录（复杂任务） | organize_downloads / smart_organize 技能 + 27 个文件整理类的能力 | ✓（重点） |

场景 6「整理下载目录」端到端（第 4 组核心演示）

1. 用户： 整理下载目录
2. HostAgent（第 1 组）识别意图 → 规划（第 2 组）→ 执行层（第 3 组）路由到工具
3. 第 4 组： Call("organize\_downloads", {"path":"~/Downloads"})
4. SkillLibrary：扫描 → 按扩展名分类（文档/图片/视频/音频/压缩包/代码/其他）→ 建子目录 → 移动 → 返回 {success:true, result:"整理完成：共 N 个文件，分类 M 类"}
5. 界面统计更新（get\_stats）+ 审计（第 5 组）+ 中文总结（第 1 组）

四、集成数据流正确性检查

```
第4组输出接口 tool_result_json:
{"success":true, "result":"...", "tool":"<name>", "elapsed_ms":N, "ts":"..."}
```

- 与设计书第 4 组契约、MCP CallToolResult 对齐；错误统一 {success:false,error}；

- 与安全（第 5 组）协同：删除/外发类操作前置确认；与 RAG（第 5 组）：审计时间戳与执行轨迹入库。

4.1 与第 5 组（系统协调+安全+RAG）的集成验证（09-09 补齐）

对照设计书第 5 组职责，本轮新增 `core/coordinator.py` 并与 Agent 打通，验证数据流闭环：

| 第 5 组职责               | 集成验证                                                        | 结果                  |
|-----------------------|-------------------------------------------------------------|---------------------|
| SystemCoordinator 编排  | <code>register/orchestrate</code> 按 1→5→2→3→4 数据流，审计+RAG 存储 | ✅ 27 项测试全绿          |
| SecuritySandbox 四层安全  | 权限检查(危险指令/受保护路径) → 沙箱执行 → 签名验证(SHA256) → 隐私保护(脱敏)           | ✅ 危险操作拦截 + 隐私脱敏测试通过 |
| RAGKnowledgeBase 向量检索 | 存储「用户输入→动作→结果」，词频向量+余弦相似度召回                                 | ✅ 检索相关性测试通过         |
| 审计日志                  | JSON Lines 可落盘、线程安全、事后查询                                    | ✅ 持久化测试通过           |
| 降级 Mock               | MockCoordinator 基于 61 同构工具 Mock 跑端到端编排                      | ✅ 测试通过              |

Agent 集成：`agent.run / run_stream` 每次对话结束自动记录一条审计（`agent_turn`）+ 存一条 RAG 轨迹；`agent.coordinator.enabled` 可关（默认开）。这使「工具调用（第 4 组）→ 审计/RAG（第 5 组）」成为运行时闭环，数据流正确性由测试保障。

4.2 安全机制实测 + 危险指令硬拦截（09-11 浏览器验证）

- 实测环境：Web 界面（真实 LLM qwen3.7-flash），授权档位调至最低档 base（基础授权）。
- 实测结果：`rm -rf /`、`format` → 直接拒绝；`shutdown` 修复前仅弹确认窗（截图 `security_test_3`）、修复后直接拒绝、无确认弹窗（截图 `security_test_6`）；正常操作（列出目录）不受影响。
- 发现并修复：`DANGEROUS_ACTIONS` 硬拦截原先只在 `SystemCoordinator.orchestrate` 契约路径，未接入 Agent 工具执行链 → 新增 `core/agent.py::_sandbox_guard` 接入 `_execute_one`，带 `cmd/command` 参数的工具命中危险指令绕过确认门直接拒绝（杜绝确认弹窗被误点的社交工程绕过）；`DANGEROUS_ACTIONS` 扩充 Windows/PowerShell 变体。
- 回归：新增 `TestSandboxGuard` 19 例（任意授权档位 + coordinator 关闭均拦截），全量 583 全绿；记录见 `docs/第4组安全机制验证记录.md`。

4.3 浏览器视觉定位端到端验证（09-11 真实 Chrome）

- 验证方式：`examples/browser_som_dom_demo.py`（不依赖 LLM，直接走 Agent 调用的同一条工具面）对真实 Chrome（CDP）按 Level 1（结构化）→ Level 3（SoM 视觉）全链路冒烟：  
1. `browser_launch(headless) → browser_navigate(bing)`，`browser_wait("#sb_form_q")`；  
2. Level 1: `browser_find(role="textbox")` 命中搜索框拿到稳定 `ref=eid:sb_form_q` → `browser_type("湖南`

大学", target=ref, press\_enter=True) 精确输入中文; 3. browser\_find(text="搜索") 按文字找按钮 → browser\_click(target=ref) 点击; 4. Level 3 兜底: browser\_inspect 截"交互元素带编号覆盖层"图 (image\_path 落实际 PNG) → 取首元素 num=1 / ref=eid:sb\_form\_q → browser\_click(target='som:1') 由 num→ref→真实鼠标落点 (返回 x=830,y=313, 已按截图 DPR 换算设备像素); 5. 全程返回客观 url\_changed / page\_changed, 且结束后 som\_session\_valid: True (会话未失效、ref 稳定)。

- 结论: browser\_find (结构化局部搜索) 与 browser\_inspect / SoM (视觉定位兜底) 两条定位链路在真实 Chrome 上均自证可用; DOM 与 SoM 都定位不了的特殊页面才回退坐标点击, 符合"结构化优先、视觉辅助、坐标兜底"的守则。

---

## 五、联调结论

- 接口契约稳定: tool\_result\_json 贯穿真机与 Mock, 无协议漂移;
- Mock 可用: 61 工具同构 Mock 全量通过, 支撑其它组离线开发;
- 真实 LLM 打通: qwen3.5-plus 成功用 function-calling 驱动第 4 组工具完成多步任务;
- 演示场景全覆盖: 设计书 6 个演示场景全部可支撑, 核心场景 6 完整跑通;
- 583 项测试全绿, 为整体集成提供可回归的安全网。

---

## 六、P1 观测成本优化后的端到端回归 (2026-09-11)

在 \_MAX\_HISTORY\_IMAGES 历史图片裁剪 + 成功结构化动作不自动截图 + System Prompt 结构化读文字等 P1 改动之后, 重跑同款豆包 E2E (python examples/miniyu\_web.py) :

- 功能无回退: 打开浏览器 → 进豆包聊天页 → 输入"你好" → 发送 → browser\_read\_text 读取回复, 全程可见前置、未逃逸桌面工具, 成功闭环;
- 成本显著下降: 账单 274,606 → 147,362 (-46%); 图片峰 6 → 2 (全程封顶); 末轮 prompt 29,284 → 19,664;
- 口径一致: run\_log cum\_total\_used=147,362 与官网账单逐分一致, P1 后观测记录可直接作性能基准;
- 回归: 全量 590 项测试全绿, 接口契约无协议漂移、Mock 与真机行为一致。

结论: P1 改动在保持浏览器链路稳定 (DOM/Ref → SoM 按需 → XY 兜底) 的前提下, 把"观察生命周期"这层成本降到健康区间, 为下一阶段 P2 (元素定位可靠性 + Benchmark) 提供可信基线。